

Laboratorio 4. Parte 2

Análisis de modelos usando datos geospaciales.

INSTRUCCIONES

Ejercicio.

Los lagos Atitlán y Amatitlán son cuerpos de agua de gran importancia ecológica, económica y cultural en Guatemala. Sin embargo, en las últimas décadas ambos han mostrado signos alarmantes de deterioro ambiental, especialmente por la proliferación de **cianobacterias** — microorganismos que pueden formar floraciones tóxicas cuando las condiciones del agua son propicias (alta temperatura, nutrientes, estancamiento, etc.).

El monitoreo constante de estas floraciones es esencial para gestionar riesgos a la salud pública, el turismo y los ecosistemas acuáticos. Sin embargo, realizar muestreos físicos frecuentes puede ser costoso, limitado en alcance espacial, y logísticamente complejo.

Aquí es donde entra en juego la **observación de la Tierra mediante satélites**. En particular, la misión **Sentinel-2** del programa Copernicus proporciona imágenes multiespectrales de alta resolución que permiten detectar cambios en la vegetación, calidad del agua y floraciones algales mediante índices espectrales.

Además, herramientas como **Sentinel Hub** y su API nos permiten acceder a scripts personalizados (como el de detección de cianobacteria) y procesar las imágenes directamente desde la nube, sin necesidad de descargar grandes volúmenes de datos.

En la primera parte del laboratorio se analizaron los lagos Atitlán y Amatitlán utilizando imágenes multiespectrales de Sentinel-2. A partir de estas imágenes se obtuvieron índices espectrales como NDVI y NDWI, así como información relacionada con la presencia de cianobacteria. También se estudiaron los patrones temporales y espaciales de las floraciones y las diferencias observadas entre ambos lagos.

En esta segunda parte se utilizarán los datos obtenidos para desarrollar modelos de Aprendizaje de Máquinas capaces de identificar zonas con alta presencia de cianobacteria a partir de características espectrales y geográficas.

DESCRIPCIÓN DE LOS DATOS

Utilice como punto de partida los datos obtenidos en la Parte I del Laboratorio 4. Los datos deberán provenir de las imágenes Sentinel-2 correspondientes a los lagos Atitlán y Amatitlán. Utilice las mismas fechas establecidas en la Parte I.

Cada observación utilizada para los modelos deberá estar asociada a una posición geográfica dentro de alguno de los lagos. Como mínimo deberá considerar:

- coordenadas espaciales;
- fecha de adquisición;
- lago;

- bandas espectrales disponibles;
- NDVI;
- NDWI;
- información sobre presencia de cianobacteria.

Puede incorporar bandas adicionales de Sentinel-2 o construir nuevas variables si considera que pueden mejorar los modelos. Cualquier variable adicional deberá ser explicada y justificada.

IMPORTANTE: Debe tener especial cuidado con los predictores. Una variable utilizada directa o indirectamente para construir la variable respuesta no deberá incluirse posteriormente como variable predictora.

EJERCICIOS

1. Preparación de los datos para Machine Learning

- 1.1. A partir de los rasters obtenidos en la Parte I, construya un conjunto de datos adecuado para Machine Learning. Cada fila deberá representar una observación geográfica válida dentro de alguno de los lagos.
- 1.2. Incluya como mínimo: coordenadas de la observación, fecha, lago, bandas espectrales utilizadas, NDVI, NDWI e índice o categoría asociada con la presencia de cianobacteria.
- 1.3. Elimine observaciones correspondientes a áreas fuera de los límites del lago, valores NoData, píxeles no válidos, nubes u otras observaciones que considere que pueden afectar el análisis.
- 1.4. Indique el número total de observaciones, número de observaciones por lago y por fecha, variables disponibles, tipo de cada variable y porcentaje de valores faltantes.
- 1.5. Realice un análisis exploratorio de las variables que utilizará para construir los modelos. Utilice las visualizaciones y estadísticas que considere necesarias.
- 1.6. Explique las decisiones tomadas durante la preparación y limpieza de los datos.

2. Construcción de la variable respuesta

- 2.1. A partir de los resultados obtenidos mediante el índice de cianobacteria, construya una variable respuesta binaria: 0 = ausencia o baja presencia de cianobacteria; 1 = alta presencia de cianobacteria.
- 2.2. Explique y justifique el criterio utilizado para establecer el punto de corte. Báse en bibliografía científica, ¿Qué se considera desde el punto de vista científico y medio ambiental bajo o alto índice de cianobacteria? Referencie la bibliografía consultada.
- 2.3. Analice la distribución de la variable respuesta globalmente, por lago y por fecha.
- 2.4. Determine si existe desbalance entre las clases. En caso de existir, explique qué consecuencias puede tener sobre el entrenamiento y la evaluación de los modelos
- 2.5. Identifique las variables que no pueden utilizarse como predictoras debido a que producirían porque se usaron para construir la variable respuesta

3. Selección y construcción de variables predictoras

- 3.1.** Defina el conjunto de variables predictoras que utilizará para construir los modelos.
- 3.2.** Para cada variable explique brevemente qué representa, por qué podría contribuir a identificar la presencia de cianobacteria y si corresponde a una banda espectral, índice o característica espacial.
- 3.3.** Puede realizar Ingeniería de características y construir variables adicionales si considera que pueden mejorar la capacidad predictiva. Toda nueva variable deberá ser explicada y justificada.

4. Construcción de modelos de Machine Learning

- 4.1.** Construya modelos de clasificación utilizando como mínimo: Regresión Logística, Random Forest y Gradient Boosting o XGBoost.
- 4.2.** Entrene inicialmente los tres modelos utilizando una división convencional de los datos: 70 % entrenamiento y 30 % prueba.
- 4.3.** Cuando sea necesario, realice ajuste de hiperparámetros. Explique qué hiperparámetros modificó, qué valores evaluó y qué criterio utilizó para seleccionar el modelo final.
- 4.4.** Mantenga el mismo conjunto de prueba para realizar comparaciones justas entre los modelos.

5. Evaluación de los modelos

- 5.1.** Para cada modelo calcule como mínimo Accuracy, Precision, Recall, F1-score, ROC-AUC y matriz de confusión.
- 5.2.** Compare los resultados obtenidos por los tres modelos y determine cuál presenta el mejor desempeño.
- 5.3.** Desde el punto de vista ambiental, analice las consecuencias de clasificar una zona sin alta presencia como alta presencia y de no detectar una zona que sí presenta alta presencia de cianobacteria. Determine cuál de estos errores considera más importante reducir y teniendo en cuenta esto compare los modelos usando la métrica más adecuada

6. Validación espacial

- 6.1.** Divida cada lago utilizando una cuadrícula regular de aproximadamente 1 km × 1 km. Antes de realizar la validación espacial, evalúe si este tamaño produce un número suficiente de bloques con observaciones válidas. Reporte el número de bloques obtenidos para cada lago y la cantidad de observaciones por bloque. Si considera necesario utilizar un tamaño diferente, puede hacerlo, pero deberá justificar su decisión. Antes de construir los bloques espaciales, reprojete los datos al sistema de referencia de coordenadas WGS 84 / UTM zona 15N (EPSG:32615). Este sistema utiliza metros como unidad de medida y será utilizado para ambos lagos.
- 6.2.** Asigne cada observación a uno de los bloques espaciales y visualice en un mapa los bloques generados.

- 6.3. Realice una validación en la cual las observaciones pertenecientes al mismo bloque espacial permanezcan dentro del mismo grupo de entrenamiento o validación. Puede utilizar GroupKFold, Spatial Cross-Validation u otra estrategia equivalente.
- 6.4. Entrene nuevamente los modelos utilizando validación espacial.
- 6.5. Compare los resultados de validación aleatoria y validación espacial.
- 6.6. Explique si el desempeño aumentó o disminuyó, cuál fue la magnitud de la diferencia, por qué puede ocurrir y qué estrategia proporciona una estimación más realista de la capacidad del modelo para predecir nuevas zonas.
- 7. **Generalización entre lagos**
 - 7.1. **Experimento A:** utilice Lago Atitlán para entrenamiento y Lago Amatitlán para evaluación.
 - 7.2. **Experimento B:** utilice Lago Amatitlán para entrenamiento y Lago Atitlán para evaluación.
 - 7.3. Calcule las métricas de evaluación para ambos experimentos.
 - 7.4. Compare estos resultados con los obtenidos cuando entrenamiento y prueba contienen observaciones del mismo lago.
 - 7.5. Responda: ¿Un modelo entrenado en un lago puede generalizar adecuadamente al otro?
 - 7.6. Discuta qué características geográficas, ambientales o espectrales podrían explicar las diferencias encontradas.
- 8. **Interpretación y explicabilidad del modelo**
 - 8.1. Para el modelo que presente el mejor desempeño, determine la importancia de las variables predictoras. Genere un gráfico de importancia global.
 - 8.2. Utilice SHAP (SHapley Additive exPlanations) para interpretar el mejor modelo obtenido. Genere un SHAP Summary Plot.
 - 8.3. Identifique las variables que presentan mayor influencia sobre las predicciones y analice si valores altos o bajos de estas variables tienden a aumentar o disminuir la predicción de alta presencia de cianobacteria. Interprete los resultados desde el contexto ambiental del problema.
 - 8.4. No se limite a mostrar las gráficas; explique los patrones encontrados y su posible significado ambiental.
- 9. **Generación de mapas predictivos**
 - 9.1. Utilice el mejor modelo para calcular, para cada observación, la probabilidad correspondiente a alta presencia de cianobacteria.
 - 9.2. Reconstruya espacialmente las predicciones y genere un mapa de probabilidad de presencia de cianobacteria.
 - 9.3. Genere como mínimo un mapa predictivo para cada lago.
 - 9.4. Utilice una escala que permita distinguir claramente zonas de probabilidad muy baja, baja, alta y muy alta.
 - 9.5. Compare el mapa predictivo con los mapas de cianobacteria obtenidos en la Parte I.

- 9.6. Identifique zonas correctamente detectadas, falsos positivos, falsos negativos y posibles patrones espaciales de error.
- 9.7. Explique si existen regiones del lago donde el modelo presenta sistemáticamente mayor dificultad para realizar predicciones.

10. Análisis y conclusiones

- 10.1. A partir de todos los experimentos realizados, determine si considera que el modelo desarrollado tiene suficiente capacidad para ser utilizado como herramienta de apoyo en el monitoreo de cianobacteria. Justifique su respuesta utilizando los principales resultados obtenidos durante el laboratorio.
- 10.2. Discuta las principales limitaciones encontradas durante el desarrollo del modelo. Considere aspectos relacionados con los datos disponibles, resolución espacial, cantidad de fechas, nubosidad, diferencias entre lagos y metodología de validación.
- 10.3. Explique qué información o datos adicionales considera que podrían mejorar el modelo. Puede considerar variables ambientales, meteorológicas, hidrológicas, temporales o información obtenida mediante muestreos físicos.

REFERENCIAS

- En estos dos sitios, hay datos de precipitaciones y temperatura de los lagos que pudieran usar:
- https://weatherspark.com/y/11701/Average-Weather-in-Amatitl%C3%A1n-Guatemala-Year-Round#google_vignette
 - <https://weatherspark.com/compare/y/11701~11135/Comparison-of-the-Average-Weather-in-Amatitl%C3%A1n-and-Santiago-Atitl%C3%A1n>

EVALUACIÓN

NOTA: La evaluación de cada integrante del grupo será de acuerdo con sus contribuciones al trabajo grupal, es necesario versionar.

(10 puntos) Preparación del conjunto de datos:

- Se construye correctamente el conjunto de datos para los modelos de aprendizaje automático.
- Se mantienen las coordenadas y fechas de las observaciones.
- Se eliminan correctamente observaciones inválidas.
- Se define y justifica adecuadamente la variable respuesta.
- Se identifican y evitan posibles problemas entre predictores y variable respuesta.
- Se realiza un análisis exploratorio adecuado.

(10 puntos) Construcción de modelos:

- Se implementa correctamente los modelos de Regresión Logística, Random Forest y Gradient Boosting o XGBoost.
- Se realiza correctamente la división entrenamiento/prueba.
- Se justifican las variables utilizadas.
- Se realiza el ajuste de hiperparámetros cuando corresponde.

(20 puntos) Evaluación de modelos:

- Se calculan correctamente Accuracy, Precision, Recall, F1 y ROC-AUC.
- Se generan e interpretan las matrices de confusión.
- Se comparan los modelos usando las métricas más adecuada de acuerdo a la revisión de bibliografía medio ambiental
- Se interpretan los errores desde el contexto ambiental.

(20 puntos) Validación geoespacial y temporal

- Se implementa correctamente una estrategia de validación espacial.
- Se representan los bloques espaciales utilizados.
- Se implementa correctamente una estrategia de validación temporal.
- Se comparan los resultados con la división aleatoria.
- Se explican las diferencias encontradas.
- Se demuestra comprensión del efecto de la dependencia espacial sobre la evaluación del modelo.

(10 puntos) Generalización entre lagos

- Se entrena con Atitlán y se evalúa con Amatitlán.
- Se entrena con Amatitlán y se evalúa con Atitlán.
- Se comparan correctamente los resultados.
- Se interpretan las diferencias observadas entre ambos lagos.

(10 puntos) Interpretabilidad y mapas predictivos

- Se analiza la importancia de las variables.
- Se utiliza correctamente SHAP.
- Se interpretan los resultados obtenidos.
- Se generan mapas de probabilidades para ambos lagos.
- Se identifican y analizan espacialmente los errores del modelo.

(20 puntos) Análisis y conclusiones

- Se identifican las limitaciones de los modelos.
- Las conclusiones se sustentan con evidencia.
- Se explica correctamente la importancia de considerar la dimensión espacial de los datos.

FECHAS DE ENTREGA

- 20 de agosto de 2026 17:20:
 - .1. Avances: Ejercicios 1, 2 y 3, con sus incisos.
- 17 de agosto de 2025 23:59
 - .1. Ejercicios Completos.

NOTA: Para poder tener nota completa debe entregar las asignaciones en el tiempo adecuado. No se calificará el avance del laboratorio si no fue entregado en tiempo, aunque esté en el repositorio.

MATERIAL A ENTREGAR

- Archivo .pdf con el informe que contenga, los resultados de los análisis y las explicaciones.
- jupyter notebook o rmarkdown usado para obtener los resultados. Este archivo debe encontrarse versionado para comprobar colaboración de cada miembro del grupo.
- Link del repositorio usado para versionar el código.