

Monitoreo exploratorio de cianobacterias en los lagos Atitlán y Amatitlán

Laboratorio 4: análisis de datos geoespaciales

Resumen ejecutivo

Se analizaron 22 de 22 escenas oficiales a partir de los GeoTIFF persistidos y validados, sin una nueva descarga.

En el período observado, Amatitlán presentó la mayor extensión alta media (26.5 %) y 81.8 % de fechas con al menos 5 % de extensión alta. Estas señales ópticas orientan vigilancia; no demuestran toxicidad, especie ni causa.

Este estudio utiliza observaciones Sentinel-2 para describir señales ópticas compatibles con clorofila-a y floraciones superficiales. Es un diagnóstico exploratorio para priorizar observación y muestreo: no sustituye análisis de agua, identificación taxonómica ni mediciones de toxinas.

Datos, alcance y validez del método

El análisis incluye las 11 fechas oficiales de cada lago. La adquisición conservó las bandas necesarias para CyanoLakes, NDVI y NDWI, además de la clasificación SCL y la máscara de datos. Se excluyeron nubes, cirros, sombras, nieve, píxeles defectuosos y zonas sin datos. Como el repositorio no contiene los GeoJSON mencionados en la guía, se emplearon sus cajas geográficas y la detección espectral de agua del script. Por tanto, “porcentaje del lago” significa porcentaje del agua válida detectada dentro de cada caja, no de un límite catastral.

El método conserva dos señales que no deben confundirse:

- **Proxy continuo:** el polinomio NDCI de CyanoLakes, calculado en agua válida sin floración superficial. Es una estimación óptica basada en datos simulados, no una concentración medida.
- **Floración superficial FAI:** clasificación independiente cuando FAI es mayor que 0.08. Se incluye en la extensión alta, pero no se le asigna artificialmente una concentración.

Tratamiento de validez

El polinomio original puede producir números negativos cuando se evalúa fuera de una respuesta físicamente posible y valores iguales o superiores al límite de 500 usado al entrenar el modelo. Esos valores se preservan en el producto raster para auditoría, pero **no se recortan a cero ni se presentan como concentración**. Las medias, percentiles, correlaciones y boxplots usan $0 \leq \text{proxy} < 500$. Las tablas informan por fecha el porcentaje interpretable, negativo e igual o superior a 500.

La extensión alta mantiene como denominador toda el agua válida detectada. Así, excluir una estimación de la media no aumenta artificialmente el porcentaje de área alta. El umbral principal es 20.0 unidades del proxy y la sensibilidad se evalúa con 10.0, 20.0, 50.0. Ninguno es un límite sanitario.

Ejercicio 4. Evolución temporal

- **Amatitlán:** la extensión alta fluctuó entre 0.0 % y 93.3 %. La fecha crítica por extensión fue 2026-06-19 (93.3 %); la mayor media interpretable ocurrió el 2026-06-19 (67.10). La cobertura del proxy interpretable varió entre 98.7 % y 100.0 % del agua válida.
- **Atitlán:** la extensión alta fluctuó entre 0.0 % y 13.9 %. La fecha crítica por extensión fue 2025-01-18 (13.9 %); la mayor media interpretable ocurrió el 2025-01-18 (39.13). La cobertura del proxy interpretable varió entre 9.0 % y 96.0 % del agua válida. La media máxima de Atitlán requiere cautela: solo 9.0 % del agua válida tuvo un proxy dentro del intervalo interpretable en esa fecha.

La fecha crítica se define reproduciblemente como la de mayor porcentaje de agua válida con proxy igual o superior al umbral o con floración FAI. Una media alta describe intensidad entre los píxeles interpretables; una extensión alta describe cuánta superficie fue clasificada. Ambas medidas deben leerse juntas.




Figura 1: Evolución temporal de la media interpretable y la extensión alta

Evidencia por fecha

Amatitlán

Fecha	Media proxy	Área alta (%)	FAI (%)	Proxy válido (%)	Negativo (%)	>=500 (%)
2025-01-28	14.91	19.6	0.00	100.0	0.0	0.0
2025-04-15	10.44	12.3	0.00	100.0	0.0	0.0
2025-04-28	13.60	23.4	0.06	99.9	0.1	0.0
2025-11-24	13.13	15.1	0.20	99.8	0.0	0.0
2026-01-08	23.13	40.2	0.26	99.7	0.0	0.0
2026-02-02	6.68	0.0	0.00	100.0	0.0	0.0
2026-02-07	8.12	1.4	0.00	100.0	0.0	0.0
2026-03-29	17.21	22.7	0.00	100.0	0.0	0.0
2026-04-13	16.57	20.8	0.00	100.0	0.0	0.0
2026-04-28	24.05	42.3	1.29	98.7	0.0	0.0
2026-06-19	67.10	93.3	0.27	99.7	0.0	0.0

Atitlán

Fecha	Media proxy	Área alta (%)	FAI (%)	Proxy válido (%)	Negativo (%)	>=500 (%)
2025-01-18	39.13	13.9	0.00	9.0	31.6	10.5
2025-04-13	3.23	0.0	0.00	94.7	5.3	0.0
2025-05-13	3.62	0.0	0.00	93.5	6.5	0.0
2025-07-17	4.24	0.2	0.00	95.6	4.4	0.0
2025-11-21	6.05	2.3	0.00	69.4	30.1	0.1
2025-12-29	4.11	0.4	0.00	66.8	32.9	0.0
2026-02-12	4.50	0.7	0.00	70.0	21.9	0.2
2026-03-24	3.67	0.0	0.00	96.0	4.0	0.0
2026-04-13	3.55	0.0	0.00	87.7	12.3	0.0
2026-04-28	3.13	0.0	0.00	91.5	8.5	0.0
2026-07-22	3.98	0.2	0.02	95.5	4.5	0.0

No se interpreta la unión entre puntos como cambio continuo: las fechas son irregulares y no observan lo ocurrido entre adquisiciones.

Ejercicio 5. Distribución espacial, persistencia y cambio

Para evitar afirmaciones basadas en inspección visual, cada cuadrícula se dividió por sus coordenadas centrales en cuatro zonas reproducibles: noroeste, noreste, suroeste y sureste. Sus límites geográficos están en `outputs/tables/spatial_zones.csv`. Son cuadrantes de análisis, no unidades ecológicas ni cuencas de aporte.

- **Amatitlán:** el cuadrante noreste tuvo la mayor media ponderada del proxy (28.32); el cuadrante noreste presentó la mayor superficie persistente (57.7 % de celdas evaluables). El mayor cambio entre primera y última fecha ocurrió en sureste (+83.3 puntos porcentuales).
- **Atitlán:** el cuadrante sureste tuvo la mayor media ponderada del proxy (5.26); el cuadrante suroeste presentó la mayor superficie persistente (0.8 % de celdas evaluables). El mayor cambio entre primera y última fecha ocurrió en noreste (-17.4 puntos porcentuales).

Lago	Cuadrante	Media proxy	Área alta media (%)	Persistente (%)	Primera (%)	Última (%)	Cambio (pp)
Amatitlán	noreste	28.32	39.8	57.7	66.6	96.5	+29.9
Amatitlán	noroeste	27.72	31.2	39.4	24.0	94.0	+70.0
Amatitlán	sureste	18.51	19.8	6.4	8.1	91.4	+83.3
Amatitlán	suroeste	4.87	4.8	1.2	37.5	no estimable	no estimable
Atitlán	noreste	4.52	1.8	0.0	17.4	0.0	-17.4
Atitlán	noroeste	4.56	1.5	0.0	12.5	0.0	-12.4
Atitlán	sureste	5.26	1.7	0.6	9.7	1.8	-7.9
Atitlán	suroeste	3.73	1.0	0.8	2.6	1.1	-1.5

“Persistente” significa que una celda fue alta en al menos la fracción configurada de sus observaciones y tuvo por lo menos dos observaciones válidas. No identifica por sí sola una fuente de nutrientes ni una trayectoria de transporte.

Mapas de todas las fechas

El color representa el proxy interpretable desde 0 hasta menos de 500; el rojo superpuesto representa FAI. Las áreas transparentes no deben leerse como concentración cero: pueden ser tierra, nube, dato no válido, floración FAI o estimación fuera del intervalo interpretable.

Frecuencia y cambio

Los mapas siguientes comparan únicamente la primera y la última fecha oficial: azul indica que la clasificación alta desapareció, blanco que no cambió y rojo que apareció. No resumen las fechas intermedias.




Figura 2: Distribución espacial en Atitlán



Figura 3: Distribución espacial en Amatitlán




Figura 4: Frecuencia de valores altos en Atitlán




Figura 5: Frecuencia de valores altos en Amatitlán




Figura 6: Cambio entre primera y última fecha de Atitlán

Cambio de clasificación alta: Amatitlán (2025-01-28 a 2026-06-19)




Figura 7: Cambio entre primera y última fecha de Amatitlán

Ejercicio 6. Relación con NDVI y NDWI

- **Amatitlán:** NDVI: moderada positiva ($r=0.50$), $n=257381$; NDWI: débil negativa ($r=-0.28$), $n=257381$.
- **Atitlán:** NDVI: moderada positiva ($r=0.33$), $n=1797665$; NDWI: débil positiva ($r=0.12$), $n=1797665$.

Lago	Índice	Pares válidos	Pearson r	Lectura
Amatitlán	NDVI	257381	0.499	moderada positiva
Amatitlán	NDWI	257381	-0.279	débil negativa
Atitlán	NDVI	1797665	0.333	moderada positiva
Atitlán	NDWI	1797665	0.116	débil positiva

Una asociación positiva indica que ambas señales tienden a aumentar juntas; una negativa, que una tiende a disminuir cuando la otra aumenta; una relación débil tiene poca utilidad predictiva lineal por sí sola. Ambientalmente, NDVI puede responder a vegetación o materia flotante y NDWI al contraste espectral agua-tierra. Sin embargo, ambos comparten bandas o condiciones ópticas con NDCI y también responden a turbidez, mezcla de orilla y corrección atmosférica. Por ello estas correlaciones describen covariación espectral, no causalidad ni identidad de organismos.

Ejercicio 7. Comparación entre lagos

Lago	Fechas	Media temporal proxy	Máxima media	Área alta media (%)	Área alta máxima (%)	Fechas $\geq 5\%$ (%)
Amatitlán	11	19.54	67.10	26.5	93.3	81.8
Atitlán	11	7.20	39.13	1.6	13.9	9.1

La intensidad se resume con la media temporal del proxy interpretable y su máxima media por fecha. La frecuencia se define como el porcentaje de fechas con al menos 5 % de extensión alta. La extensión media y máxima cuantifica superficie y no concentración. Esta separación evita concluir que un evento localizado pero intenso equivale a uno extendido.

Hipótesis causales que requieren medición

Los raster no midieron nutrientes, uso del suelo, descargas, presión urbana, profundidad, circulación, temperatura ni precipitación. Por tanto, las siguientes son **hipótesis de trabajo**, no resultados del estudio:

- **Presión urbana y uso del suelo:** si las zonas con mayor recurrencia reciben más aportes de aguas residuales o escorrentía agrícola, deberían coincidir con concentraciones de nutrientes y trazadores medidos en campo.
- **Geografía y circulación:** si la forma, profundidad o circulación retienen material flotante, la persistencia debería repetirse bajo condiciones comparables de viento y nivel del lago.
- **Temperatura y clima:** si temperatura, radiación o lluvia modulan la proliferación, una serie más larga debería mostrar asociaciones consistentes después de controlar nubosidad y cobertura.

Estas hipótesis pueden explicar diferencias potenciales entre lagos, pero no se aceptan ni se rechazan con los índices disponibles.

Ejercicio 8. Análisis exploratorio adicional

Extensión y sensibilidad al umbral

Lago	Umbral	Área media (%)	Máxima (%)
Amatitlán	10	51.3	98.3
Amatitlán	20	26.5	93.3
Amatitlán	50	10.2	67.1
Atitlán	10	2.2	14.3
Atitlán	20	1.6	13.9
Atitlán	50	1.3	12.6

La variación entre umbrales muestra cuánto depende la extensión de la convención analítica. FAI se conserva como alta en todos los umbrales porque el script la trata como una rama independiente.

Distribuciones y diferencias

Los boxplots comparan solo el proxy interpretable desde 0 hasta menos de 500. La línea central es la mediana, la caja resume el rango intercuartílico y se ocultan valores atípicos para legibilidad, no para el cálculo de estadísticas.




Figura 8: Distribuciones interpretables por fecha

Los mapas de frecuencia y diferencia del Ejercicio 5 complementan los boxplots: los primeros localizan recurrencia y los segundos muestran dónde apareció o desapareció la clasificación alta.

Estacionalidad exploratoria

- **Amatitlán:** lluviosa (n=1, área alta media 93.3 %, proxy medio 67.10); seca (n=10, área alta media 19.8 %, proxy medio 14.79).
- **Atitlán:** lluviosa (n=3, área alta media 0.1 %, proxy medio 3.95); seca (n=8, área alta media 2.2 %, proxy medio 8.42).

Lago	Época	n	Proxy medio	Área alta media (%)
Amatitlán	lluviosa	1	67.10	93.3
Amatitlán	seca	10	14.79	19.8
Atitlán	lluviosa	3	3.95	0.1

Lago	Época	n	Proxy medio	Área alta media (%)
Atitlán	seca	8	8.42	2.2

La época seca se definió como noviembre-abril y la lluviosa como mayo-octubre. Con 11 fechas irregulares por lago, grupos muy desbalanceados y poco más de un ciclo anual, estas diferencias no demuestran estacionalidad. Sirven para diseñar una serie mensual que incluya varios años.

Limitaciones

- El modelo fue entrenado con datos simulados bajo restricciones ópticas y aquí se aplicó a L2A para disponer de SCL; los valores no son intercambiables automáticamente con medición de campo.
- No existe una geometría oficial del contorno en el repositorio; el agua detectada puede incluir bordes, cuerpos vecinos o píxeles mixtos dentro de la caja.
- Nubes, bruma, turbidez, fondo visible, vegetación flotante y efectos de adyacencia pueden alterar las señales. La máscara reduce estos problemas, pero no los elimina.
- Una escena es una instantánea. Once observaciones irregulares por lago no caracterizan duración, inicio o fin de una floración ni permiten inferir tendencias de largo plazo.
- La correlación por píxel tiene tamaños muestrales grandes por resolución espacial, pero existe autocorrelación espacial; n no equivale a igual número de muestras independientes.
- Sentinel-2 no confirma especie, toxina ni riesgo sanitario. No debe emitirse una alerta pública solo con estos resultados.

Recomendaciones de monitoreo

- En Amatitlán, priorizar verificación de campo en el cuadrante noreste y contrastarla con el cuadrante de mayor media (noreste); las coordenadas exactas están en `spatial_zones.csv`.
- En Atitlán, priorizar verificación de campo en el cuadrante suroeste y contrastarla con el cuadrante de mayor media (sureste); las coordenadas exactas están en `spatial_zones.csv`.
- Muestrear clorofila-a, ficocianina, composición taxonómica y toxinas en fechas críticas y en una zona de contraste; registrar coordenada, hora, profundidad y condiciones meteorológicas.
- Mantener observación mensual y aumentar frecuencia después de una señal extensa; conservar también fechas sin evento para estimar falsos positivos y negativos.
- Incorporar contornos oficiales y calcular área física en hectáreas con una proyección adecuada.
- Integrar precipitación, viento, temperatura del agua, nutrientes, uso del suelo y descargas antes de evaluar las hipótesis causales.
- Calibrar y validar el proxy localmente con muestras coincidentes con el paso satelital antes de usarlo para decisiones operativas.

Proveniencia y reproducibilidad

Contiene datos Copernicus Sentinel modificados, procesados mediante Sentinel Hub. El polinomio, FAI y la lógica de agua reproducen el script *Cyanobacteria Chlorophyll-a NDCI L1C* de CyanoLakes, atribuido a Kravitz y Matthews (2020) en el repositorio oficial de scripts de Sentinel Hub. Las restricciones de entrenamiento y la referencia metodológica se documentan en esa misma fuente.

Todas las cifras del informe se regeneran desde los 22 GeoTIFF persistidos. Las tablas CSV y los GeoTIFF de frecuencia permiten auditar fechas, denominadores, cuadrantes, correlaciones y umbrales.